Алгоритм LZ77: Кодування

Алгоритм LZ77 є методом стиснення даних, який використовує попередні дані для стиснення подальших символів. Це досягається за допомогою пошуку співпадінь (матчів) у буфері пошуку (текст, який вже було оброблено) для поточного сегменту даних, що кодується. Кожне співпадіння кодується трійкою: відстань до співпадіння в буфері (офсет), довжина співпадіння та наступний символ після співпадіння.

Кодування (codding):

Ініціалізація: Створюємо список result для зберігання закодованих трійок та буфер buffer для зберігання останніх символів, які були оброблені. Обробка тексту: Проходимо по тексту, шукаючи співпадіння для кожного символу у буфері. Якщо символ вже зустрічався у буфері, шукаємо найбільшу підрядок, яка співпадає з частиною тексту, який ми зараз обробляємо.

Оновлення трійок: Для кожного знайденого співпадіння формуємо трійку (офсет, довжина, наступний символ) та додаємо її до результату. Якщо співпадіння не знайдено, офсет і довжина будуть рівні 0, а в якості наступного символу вказується поточний символ.

Оновлення буфера: Після обробки кожного символу оновлюємо буфер, додаючи нові символи та видаляючи старі, якщо довжина буфера перевищує заданий розмір.

Алгоритм LZ77: Декодування

Декодування відновлює оригінальний текст зі списку закодованих трійок. Кожна трійка вказує на підрядок у вже декодованому тексті, який потрібно скопіювати, та на наступний символ, який слід додати.

Декодування (decoding):

Відновлення тексту: Ітеруємо по списку закодованих трійок.

Використовуючи офсет і довжину, копіюємо відповідний підрядок з уже декодованого тексту та додаємо наступний символ.

Спеціальні випадки: Обробляємо випадки, коли офсет більший або дорівнює довжині співпадіння, а також ситуації з перекриттям (коли офсет менший за довжину).

Застосування

Алгоритм LZ77 ефективний для текстів великої довжини, де є багато повторюваних підрядків. Ефективність стиснення зростає з розміром даних, оскільки збільшується ймовірність знайти довгі співпадіння. Водночас, для дуже коротких текстів або даних з високою ентропією (де мало повторень) алгоритм може бути менш ефективним